



Déetectez des faux billets avec R ou Python

Hébert Thomas / Data Analyst

Contexte

L'ONCFM souhaite développer une application de machine learning pour détecter automatiquement les faux billets en euros, à partir de caractéristiques physiques (longueur, hauteur, etc.).

Un jeu de 1500 billets scannés (1000 vrais / 500 faux) est fourni pour entraîner les modèles. Sur recommandation de l'agence européenne **EMV**, quatre algorithmes seront testés en priorité : **Régression Logistique, Random Forest, KNN et K-means**.

L'objectif final : mettre à disposition une application simple et efficace pour prédire la nature d'un billet à partir de ses caractéristiques.

Sommaire

1. Traitements et analyses

- a. Exploration du fichier
- b. Régression linéaire

2. Algorithmes et résultats

- a. Régression logistique
- b. Random forest
- c. KNN
- d. K-means
- e. ACP

3. Modèle final et application

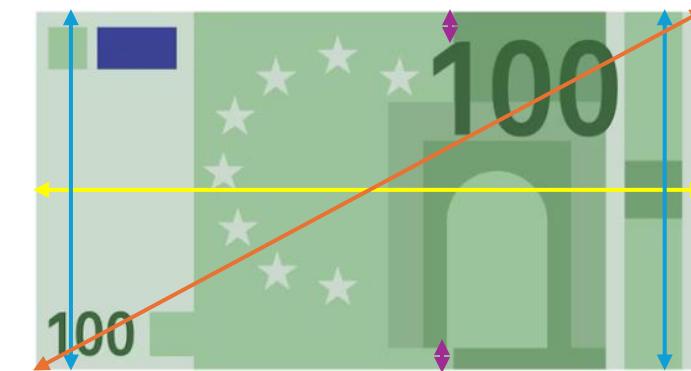
- a. Choix du modèle
- b. Application

1. Traitement et analyses

a. Exploration du fichier

Le fichier comporte 1500 échantillons réparties en 7 variables :

- 1 variable booléenne (Vrai/Faux billet)
 - 1000 vrais billets
 - 500 faux billets
- 6 variables géométriques (dimensions du billet)
 - 37 valeurs manquantes dans la variable *margin_low*



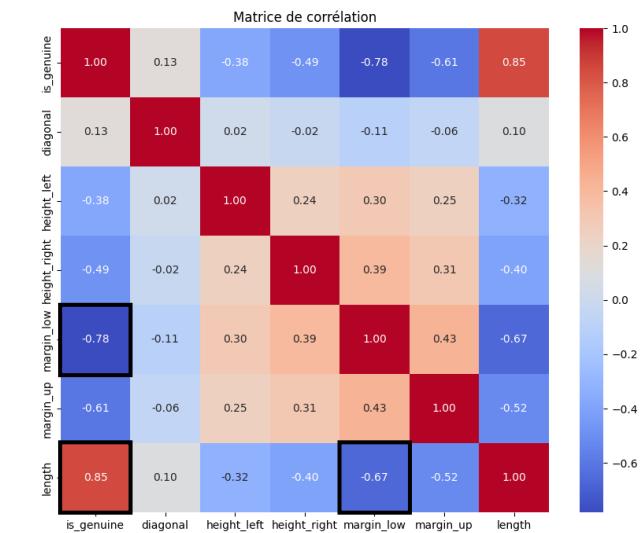
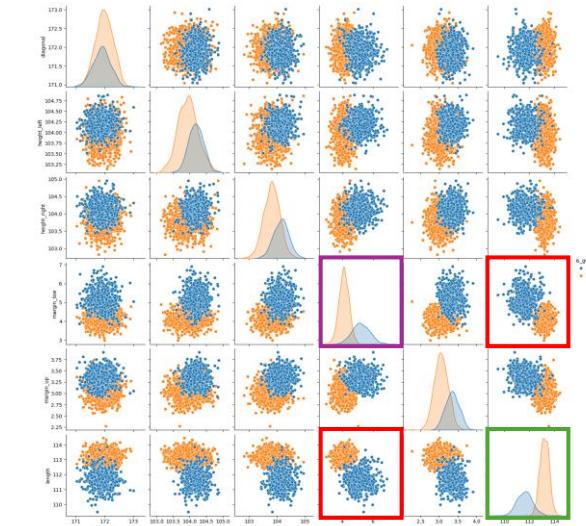
| is_genuine | diagonal | height_left | height_right | margin_low | margin_up | length |
|------------|----------|-------------|--------------|------------|-----------|--------|
| True | 171.81 | 104.86 | 104.95 | 4.52 | 2.89 | 112.83 |
| True | 171.46 | 103.36 | 103.66 | 3.77 | 2.99 | 113.09 |
| True | 172.69 | 104.48 | 103.5 | 4.4 | 2.94 | 113.16 |
| True | 171.36 | 103.91 | 103.94 | 3.62 | 3.01 | 113.51 |
| True | 171.73 | 104.28 | 103.46 | 4.04 | 3.48 | 112.54 |

Extrait du fichier

1. Traitement et analyses

a. Exploration du fichier

- Les variables *length* et *margin_low* montrent une bonne séparation entre vrais et faux billets (*pairplot* et distribution)
- Corrélation avec *is_genuine* confirmée par la heatmap
- Potentiels bons candidats pour la classification

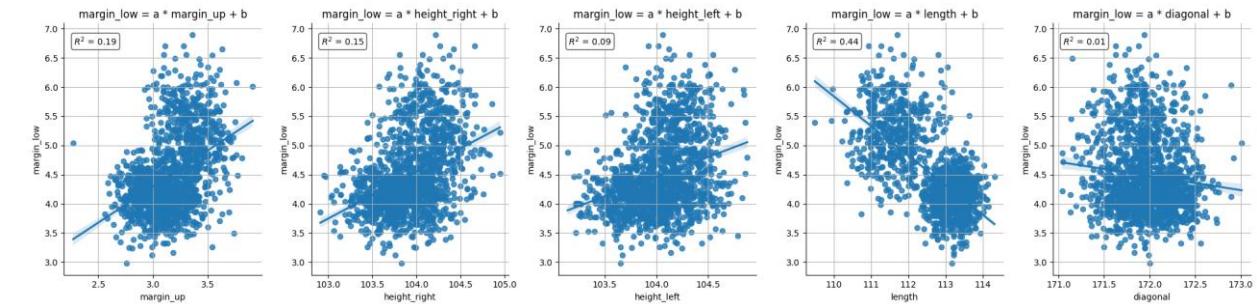


1. Traitement et analyses

b. Régression linéaire

Imputation des valeurs manquantes à la variable *margin_low*:

- Régression linéaire multiple
- Relation linéaire confirmée par les graphiques et coefficients
- *is_genuine* transformée en variable numérique
- VIF < 5 → pas de multicolinéarité



Corrélation

| | margin_low | margin_up | height_right | height_left | diagonal | length | is_genuine_num |
|----------------|------------|-----------|--------------|-------------|-----------|-----------|----------------|
| margin_low | 1.000000 | | | | | | |
| margin_up | 0.431606 | 1.000000 | | | | | |
| height_right | 0.391085 | -0.111534 | 1.000000 | | | | |
| height_left | 0.302643 | -0.666753 | -0.783032 | 1.000000 | | | |
| diagonal | | | | | 1.000000 | | |
| length | | | | | -0.783032 | 1.000000 | |
| is_genuine_num | | | | | | -0.111534 | 1.000000 |

VIF

| Feature | VIF |
|----------------|----------|
| margin_up | 1.596090 |
| height_right | 1.320836 |
| height_left | 1.173711 |
| diagonal | 1.028199 |
| length | 3.613255 |
| is_genuine_num | 4.725732 |

1. Traitement et analyses

a. Régression linéaire

Modèle cohérent mais peu performant :

- 5 variables explicatives
- P-values < 5% → variables significatives
- Coefficients interprétables
- R² moyen : 0,54
- MSE, RMSE, MAE, MAPE : très faible

| OLS Regression Results | | | | | | |
|------------------------|--|---------------------|-----------|-----------------|---------|--------|
| Dep. Variable: | margin_low | R-squared: | 0.477 | Adj. R-squared: | 0.476 | |
| Model: | OLS | F-statistic: | 266.1 | | | |
| Method: | Least Squares | Prob (F-statistic): | 2.60e-202 | Log-Likelihood: | -1001.3 | |
| Date: | Sat, 17 May 2025 | No. Observations: | 1463 | AIC: | 2015. | |
| Time: | 08:48:12 <th>Df Residuals:</th> <td>1457</td> <th>BIC:</th> <td>2046.</td> <th></th> | Df Residuals: | 1457 | BIC: | 2046. | |
| Df Model: | 5 | Covariance Type: | nonrobust | | | |
| | | | | | | |
| | coef | std err | t | P> t | [0.025 | 0.975] |
| const | 22.9948 | 9.656 | 2.382 | 0.017 | 4.055 | 41.935 |
| margin_up | 0.2562 | 0.064 | 3.980 | 0.000 | 0.130 | 0.382 |
| height_right | 0.2571 | 0.043 | 5.978 | 0.000 | 0.173 | 0.342 |
| height_left | 0.1841 | 0.045 | 4.113 | 0.000 | 0.096 | 0.272 |
| length | -0.4091 | 0.018 | -22.627 | 0.000 | -0.445 | -0.374 |
| diagonal | -0.1111 | 0.041 | -2.680 | 0.007 | -0.192 | -0.030 |
| | | | | | | |
| Omnibus: | 73.627 | Durbin-Watson: | 1.893 | | | |
| Prob(Omnibus): | 0.000 | Jarque-Bera (JB): | 95.862 | | | |
| Skew: | 0.482 | Prob(JB): | 1.53e-21 | | | |
| Kurtosis: | 3.801 | Cond. No. | 1.94e+05 | | | |

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 1.94e+05. This might indicate that there are strong multicollinearity or other numerical problems.
MSE: 0.1914495494749333
RMSE: 0.4375494823159243
MAE: 0.33537069327648383
MAPE: 0.07467677345733466
R²: 0.5457956683532408

1. Traitement et analyses

a. Régression linéaire

Modèle décousu mais performant :

- 6 variables explicatives (ajout de *is_genuine_num*)
- P-values proche ou > 5% → variables peu significatives
- Coefficients désordonnés
- R² élevé : 0,67
- MSE, RMSE, MAE, MAPE : très faible

| OLS Regression Results | | | | | | |
|------------------------|------------------|---------------------|-------------------|-------|----------|--------|
| Dep. Variable: | margin_low | R-squared: | 0.617 | | | |
| Model: | OLS | Adj. R-squared: | 0.615 | | | |
| Method: | Least Squares | F-statistic: | 390.7 | | | |
| Date: | Sat, 17 May 2025 | Prob (F-statistic): | 4.75e-299 | | | |
| Time: | 08:48:12 | Log-Likelihood: | -774.14 | | | |
| No. Observations: | 1463 | AIC: | 1562. | | | |
| Df Residuals: | 1456 | BIC: | 1599. | | | |
| Df Model: | 6 | | | | | |
| Covariance Type: | nonrobust | | | | | |
| | coef | std err | t | P> t | [0.025 | 0.975] |
| const | 2.8668 | 8.316 | 0.345 | 0.730 | -13.445 | 19.179 |
| margin_up | -0.2128 | 0.059 | -3.621 | 0.000 | -0.328 | -0.098 |
| height_right | 0.0267 | 0.038 | 0.701 | 0.484 | -0.048 | 0.102 |
| height_left | 0.0283 | 0.039 | 0.727 | 0.468 | -0.048 | 0.185 |
| length | -0.0039 | 0.023 | -0.166 | 0.868 | -0.050 | 0.042 |
| diagonal | -0.0130 | 0.036 | -0.364 | 0.716 | -0.083 | 0.057 |
| is_genuine_num | -1.1406 | 0.050 | -23.028 | 0.000 | -1.238 | -1.043 |
| Omnibus: | | 21.975 | Durbin-Watson: | | 2.038 | |
| Prob(Omnibus): | | 0.000 | Jarque-Bera (JB): | | 37.993 | |
| Skew: | | 0.061 | Prob(JB): | | 5.62e-09 | |
| Kurtosis: | | 3.780 | Cond. No. | | 1.95e+05 | |

Notes:

- [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
 - [2] The condition number is large, 1.95e+05. This might indicate that there are strong multicollinearity or other numerical problems.
- MSE: 0.13739452871780827
RMSE: 0.3706676796239568
MAE: 0.28949122166076857
MAPE: 0.06496074172211527
R²: 0.6740384594304603

1. Traitement et analyses

a. Régression linéaire

Modèle simple et performant :

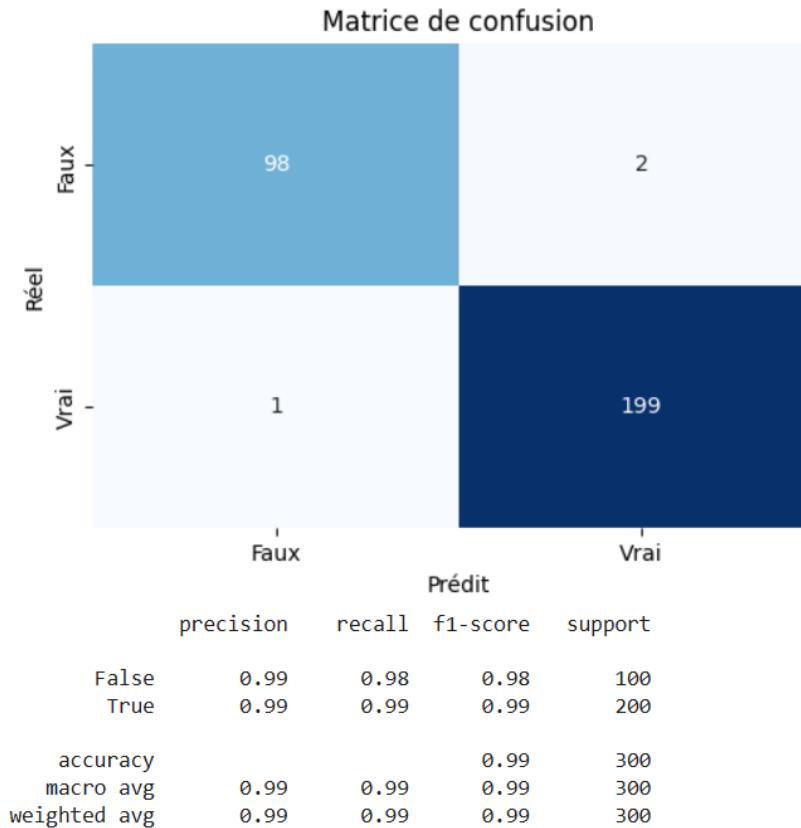
- 2 variables explicatives
- P-values < 5% → variables significatives
- Coefficients interprétables et cohérents
- R^2 élevé : 0,67
- MSE, RMSE, MAE, MAPE : très faible

| OLS Regression Results | | | | | | |
|---|---------------------|---------------------|-------------------|-------|----------|--------|
| Dep. Variable: | margin_low | R-squared: | 0.617 | | | |
| Model: | OLS | Adj. R-squared: | 0.616 | | | |
| Method: | Least Squares | F-statistic: | 1174. | | | |
| Date: | Mon, 19 May 2025 | Prob (F-statistic): | 1.24e-304 | | | |
| Time: | 15:01:38 | Log-Likelihood: | -774.73 | | | |
| No. Observations: | 1463 | AIC: | 1555. | | | |
| Df Residuals: | 1460 | BIC: | 1571. | | | |
| Df Model: | 2 | | | | | |
| Covariance Type: | nonrobust | | | | | |
| | | | | | | |
| | coef | std err | t | P> t | [0.025 | 0.975] |
| | | | | | | |
| const | 5.9263 | 0.198 | 30.003 | 0.000 | 5.539 | 6.314 |
| margin_up | -0.2119 | 0.059 | -3.612 | 0.000 | -0.327 | -0.097 |
| is_genuine_num | -1.1632 | 0.029 | -40.477 | 0.000 | -1.220 | -1.107 |
| | | | | | | |
| Omnibus: | | 22.365 | Durbin-Watson: | | 2.041 | |
| Prob(Omnibus): | | 0.000 | Jarque-Bera (JB): | | 39.106 | |
| Skew: | | 0.057 | Prob(JB): | | 3.22e-09 | |
| Kurtosis: | | 3.793 | Cond. No. | | 65.0 | |
| | | | | | | |
| Notes: | | | | | | |
| [1] Standard Errors assume that the covariance matrix of the errors is correctly specified. | | | | | | |
| MSE: | 0.13757029265899082 | | | | | |
| RMSE: | 0.3709046948462513 | | | | | |
| MAE: | 0.2897307135185014 | | | | | |
| MAPE: | 0.06504068673145773 | | | | | |
| R ² : | 0.6736214684077528 | | | | | |

2. Algorithmes et résultats

a. Régression logistique

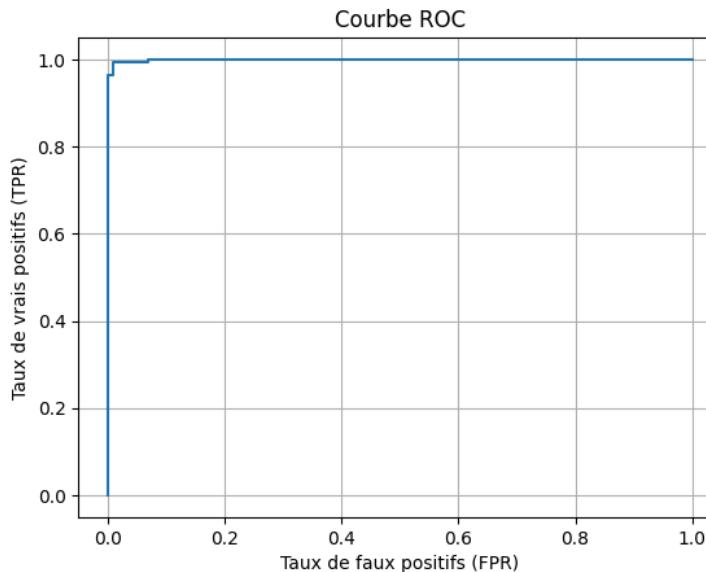
- Algorithme de **classification supervisée**
- Adapté aux problèmes binaires
- Prédit la **probabilité d'appartenance à une classe**



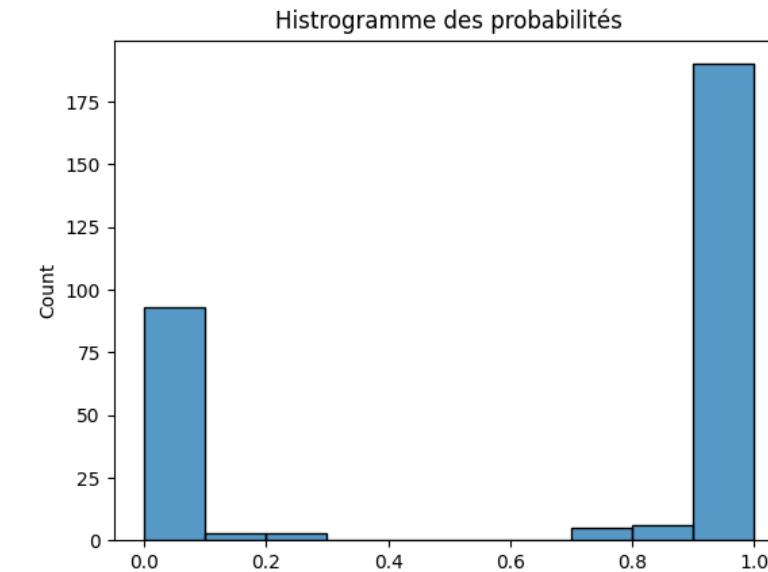
- **Précision élevée :** seulement 3 erreurs sur 300
- Rejette **1 vrai billet (faux négatif)**
- Prend **2 faux billets pour des vrais (faux positifs)**

2. Algorithmes et résultats

a. Régression logistique



- Courbe quasi parfaite
- AUC = 0,99
- Confirme une excellente performance du modèle

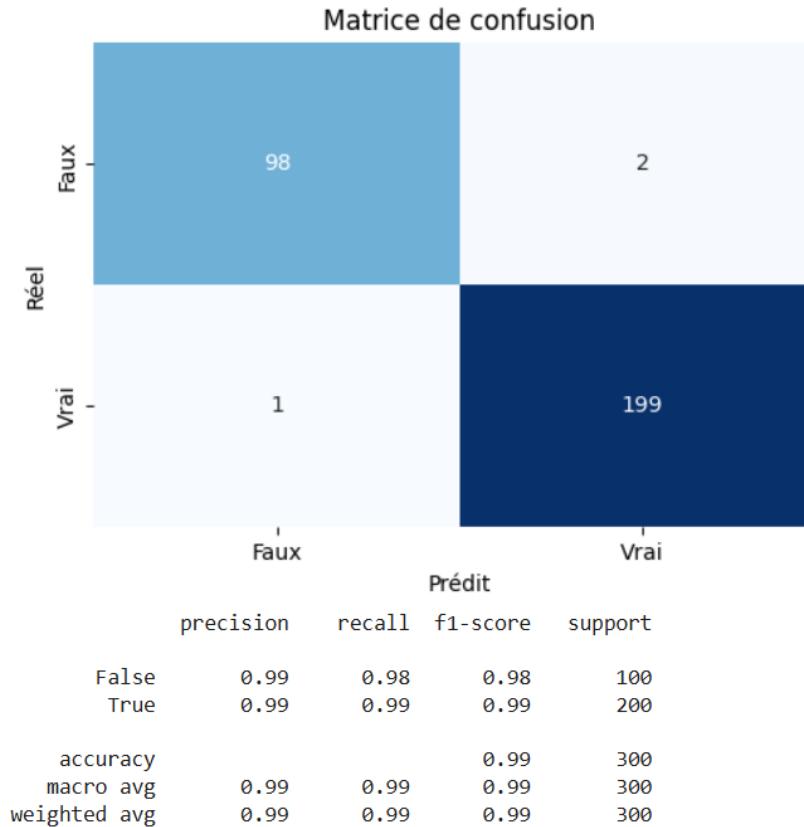


- Majorité des prédictions proches de 0 ou 1
- Forte confiance du modèle dans ses prédictions
- Bonne séparation entre les deux classes

2. Algorithmes et résultats

b. Random forest

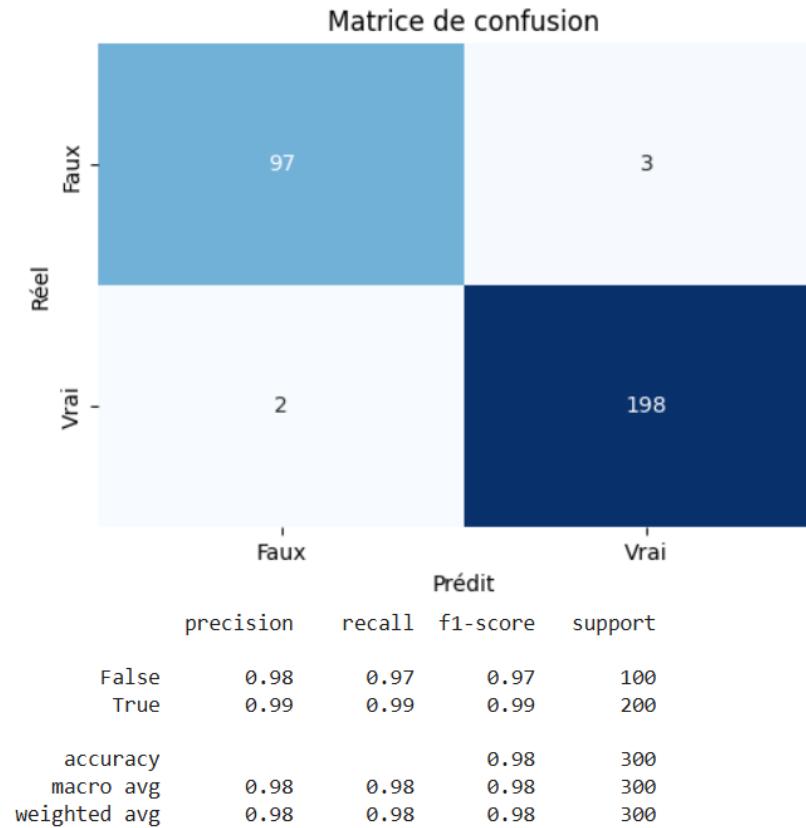
- Algorithme de classification supervisée
- Basé sur un ensemble d'arbres de décision
- Chaque arbre s'entraîne sur un échantillon différent
- La prédiction finale se fait par vote majoritaire



2. Algorithmes et résultats

c. KNN

- Algorithme de **classification supervisée**
- Basé sur la notion de **proximité** dans l'espace des variables
- Prédit la classe d'un billet en regardant les **k voisins les plus proches**
- La **classe majoritaire** parmi ces voisins est choisie comme prédition

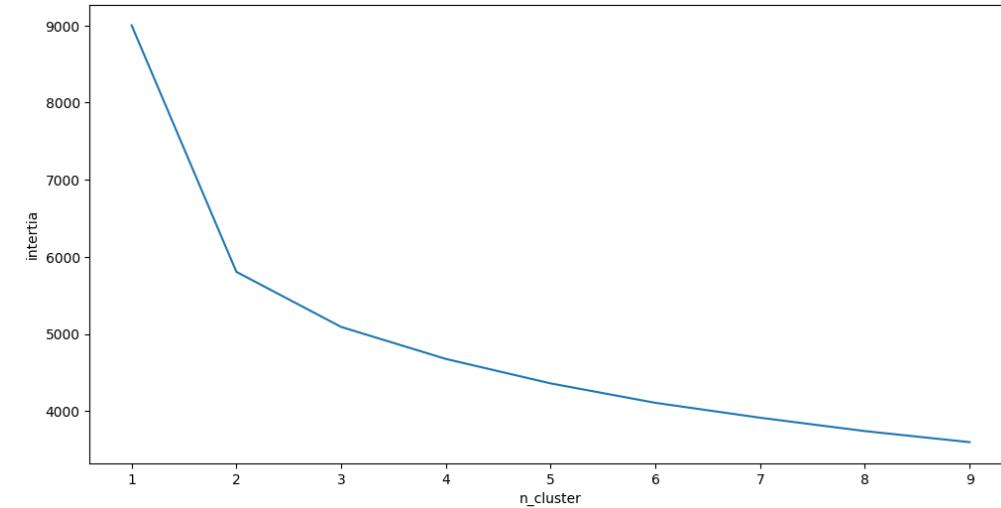


- Le modèle commet **une erreur de plus** dans chaque catégorie
- **Moins performant** que les deux algorithmes précédents

2. Algorithmes et résultats

d. K-means

- Algorithme non supervisée
- Regroupe les billets en **clusters** selon leurs caractéristiques
- Ne tient pas compte de l'**étiquette** (vrai/faux)
- Permet de détecter des **structures naturelles** ou des regroupements dans les données



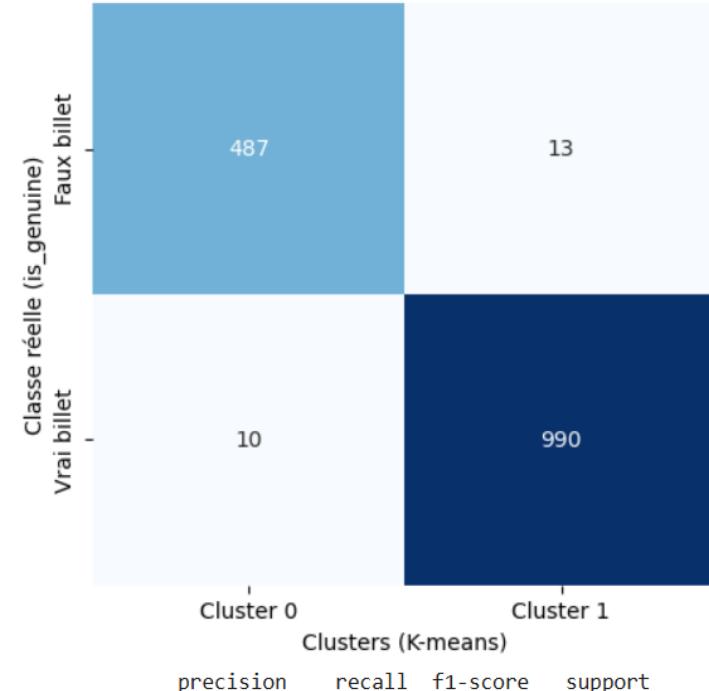
- **Méthode du coude** pour déterminer le nombre optimal de clusters
- Point d'inflexion à **k=2**
- Confirme la présence de 2 groupes distincts
- Cohérent avec la classification vrai/faux

2. Algorithmes et résultats

d. K-means

- Matrice de confusion et scores globalement satisfaisants
- Bonne performance malgré l'absence d'étiquettes
- K-means se défend bien face aux modèles supervisés

Matrice de confusion : K-means vs is_genuine

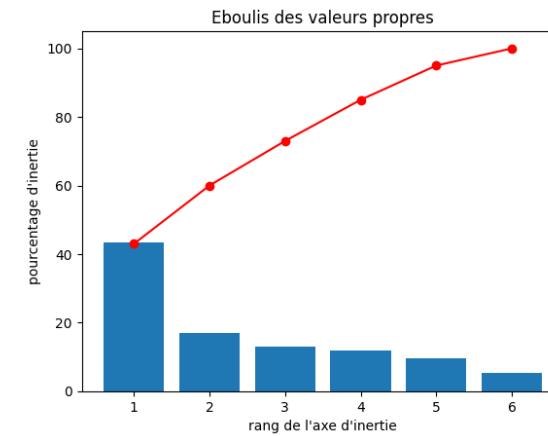


| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| False | 0.98 | 0.97 | 0.98 | 500 |
| True | 0.99 | 0.99 | 0.99 | 1000 |
| accuracy | | | 0.98 | 1500 |
| macro avg | 0.98 | 0.98 | 0.98 | 1500 |
| weighted avg | 0.98 | 0.98 | 0.98 | 1500 |

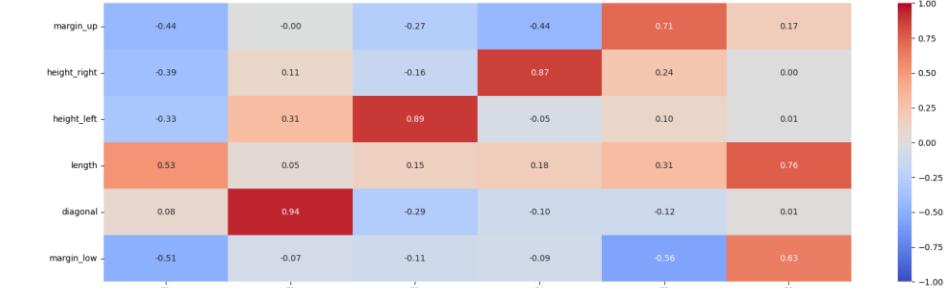
2. Algorithmes et résultats

e. ACP

- Méthode de réduction de dimension
- Résume l'information des variables en quelques axes principaux
- Facilite la visualisation et l'interprétation des données



- $F1 \approx 40\%$ de la variance

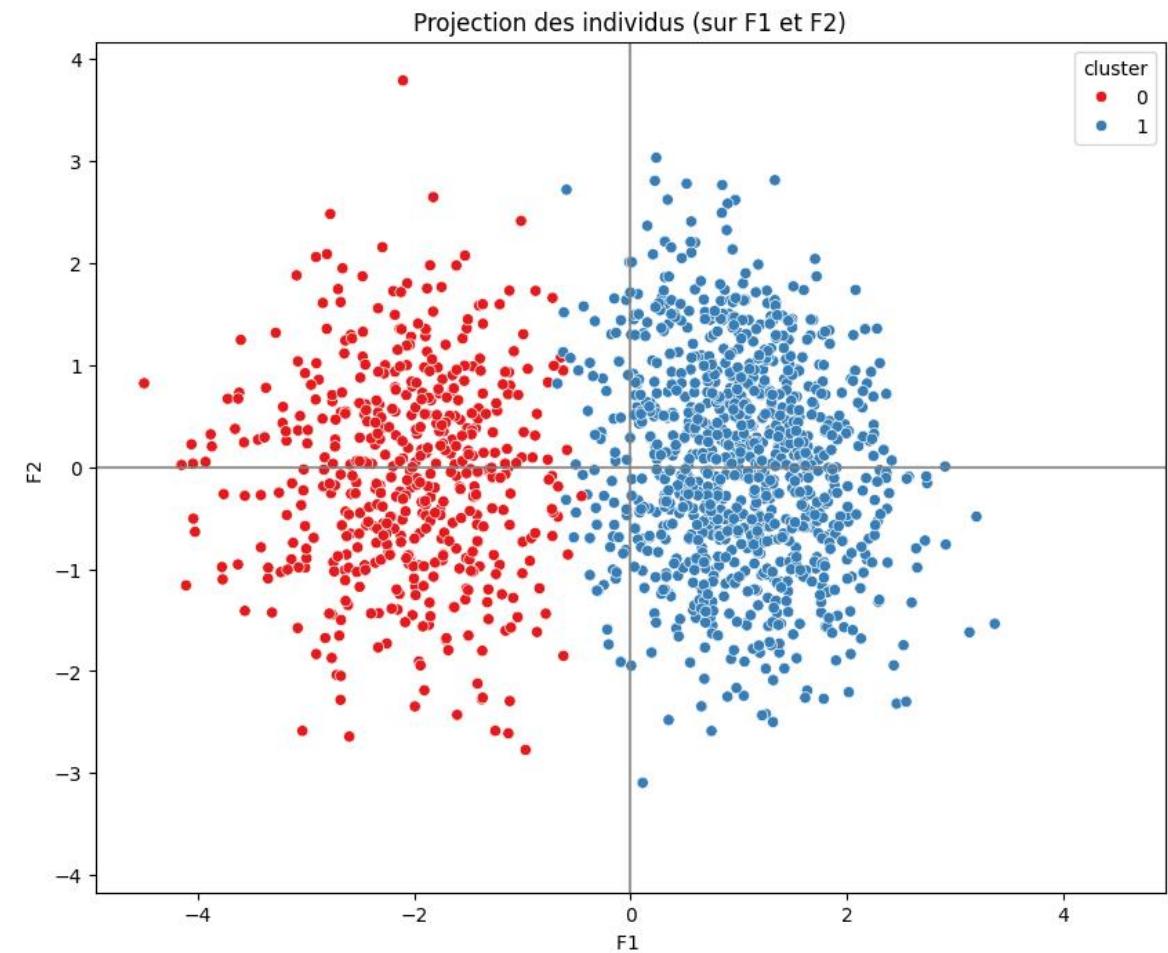


- $F1$ corrélé à *length* et *margin_low* → 2 variables influançant le plus la véracité d'un billet.

2. Algorithmes et résultats

e. ACP

- Projection sur F1 et F2 : séparation nette entre vrais et faux billets.
- Les clusters du K-means renforce la distinction.

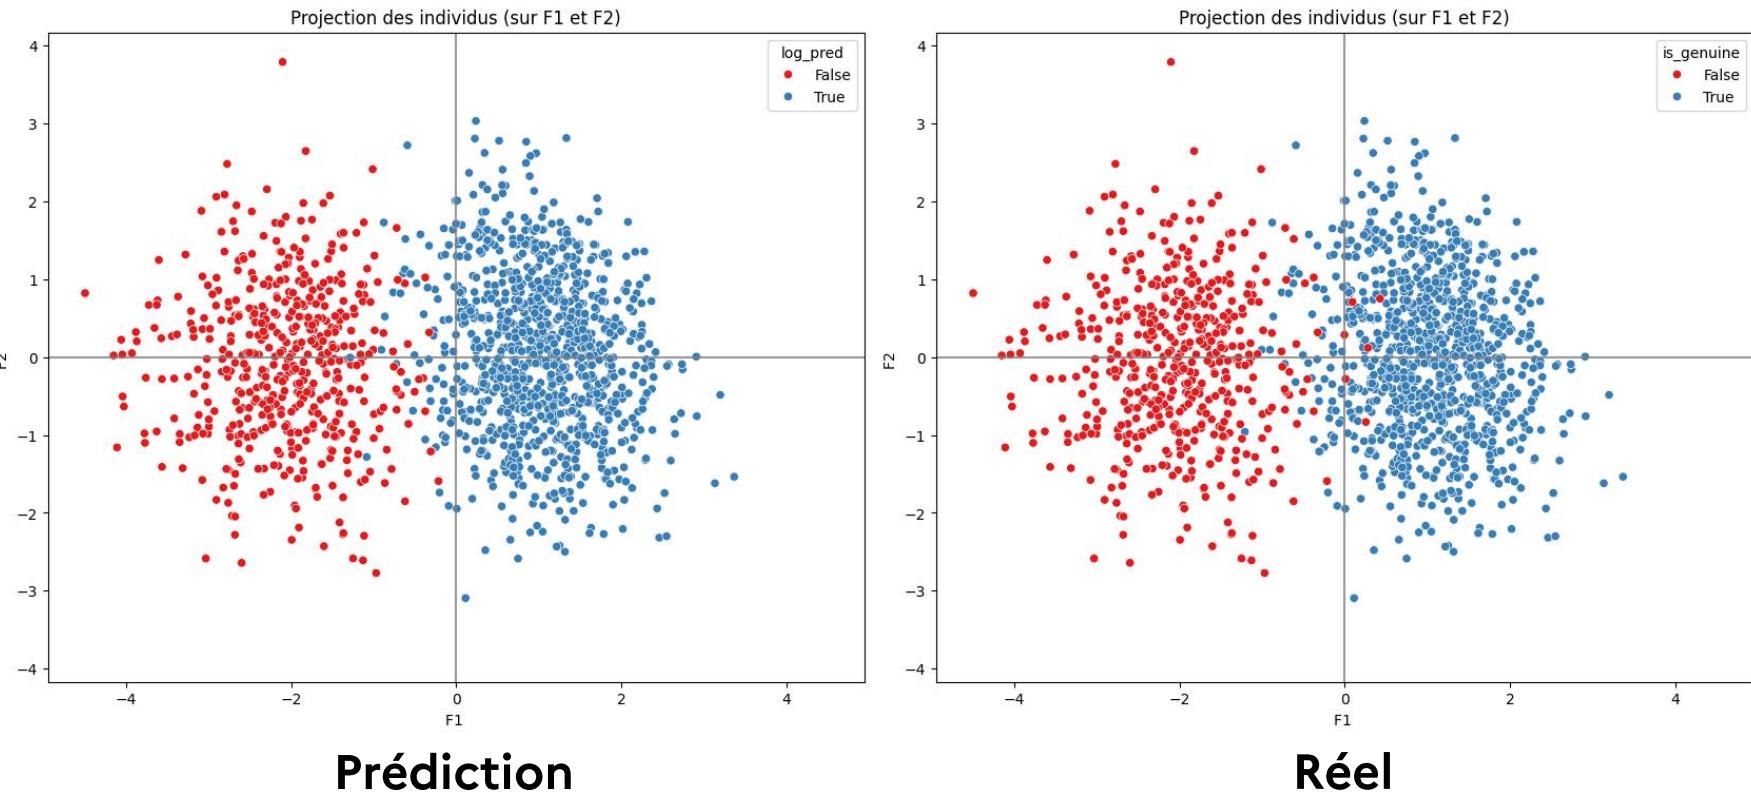


3. Modèle final et application

a. Choix du modèle

Régression logistique :

- meilleur compromis entre la performance, la simplicité et l'interprétabilité



3. Modèle final et application

b. Application

Application déployée sous deux formats :

- **Notebook Jupyter** : permet d'explorer les données si besoin
- **interface Streamlit** : utilisation simple par l'utilisateur

Permet de visualiser les données, prédire automatiquement et télécharger les résultats

Authentification des billets

Chargez votre fichier CSV

Drag and drop file here
Limit 200MB per file • CSV

Browse files

 simulated_billets.csv 4.2KB 

Aperçu des données

| | diagonal | height_left | height_right | margin_low | margin_up | length | id |
|---|----------|-------------|--------------|------------|-----------|--------|------|
| 0 | 172.05 | 103.53 | 103.94 | 4.14 | 2.88 | 112.93 | A_1 |
| 1 | 171.73 | 103.93 | 104.02 | 4.35 | 3.08 | 113.91 | A_2 |
| 2 | 172.12 | 103.96 | 104.23 | 5.4 | 3.2 | 110.6 | A_3 |
| 3 | 172.56 | 103.78 | 104.22 | 5.29 | 3.21 | 112.56 | A_4 |
| 4 | 171.68 | 104.04 | 103.25 | 4.78 | 3.11 | 111.35 | A_5 |
| 5 | 171.68 | 104.26 | 103.42 | 4.89 | 3.32 | 111.51 | A_6 |
| 6 | 172.59 | 104.85 | 104.01 | 5.82 | 2.99 | 111.41 | A_7 |
| 7 | 172.18 | 104.17 | 104.01 | 4.33 | 3.17 | 111.14 | A_8 |
| 8 | 171.57 | 104.2 | 104.01 | 5.24 | 3.22 | 112.05 | A_9 |
| 9 | 172.07 | 104.07 | 105.34 | 4.64 | 3.3 | 111.17 | A_10 |

Résultat des prédictions

Légende :  = vrai billet  = faux billet

| | diagonal | height_left | height_right | margin_low | margin_up | length | id | log_pred | probabilité |
|---|----------|-------------|--------------|------------|-----------|--------|------|---|-------------|
| 0 | 172.05 | 103.53 | 103.94 | 4.14 | 2.88 | 112.93 | A_1 |  | 1.00 |
| 1 | 171.73 | 103.93 | 104.02 | 4.35 | 3.08 | 113.91 | A_2 |  | 1.00 |
| 2 | 172.12 | 103.96 | 104.23 | 5.4 | 3.2 | 110.60 | A_3 |  | 0.00 |
| 3 | 172.56 | 103.78 | 104.22 | 5.29 | 3.21 | 112.56 | A_4 |  | 0.10 |
| 4 | 171.68 | 104.04 | 103.25 | 4.78 | 3.11 | 111.35 | A_5 |  | 0.04 |
| 5 | 171.68 | 104.26 | 103.42 | 4.89 | 3.32 | 111.51 | A_6 |  | 0.01 |
| 6 | 172.59 | 104.85 | 104.01 | 5.82 | 2.99 | 111.41 | A_7 |  | 0.00 |
| 7 | 172.18 | 104.17 | 104.01 | 4.33 | 3.17 | 111.14 | A_8 |  | 0.01 |
| 8 | 171.57 | 104.2 | 104.01 | 5.24 | 3.22 | 112.05 | A_9 |  | 0.01 |
| 9 | 172.07 | 104.07 | 105.34 | 4.64 | 3.30 | 111.17 | A_10 |  | 0.00 |

 Télécharger les résultats